



AeroPredictor

Estimaciones diarias de generación eólica peninsular
con datos de AEMET y Red Eléctrica de España

7

Estaciones AEMET

4+

Años de datos

8

Modelos ML

José Luis Alonso Redondo

Data Science Bootcamp · 2026

aero-predictor.joseluisalonsoredondo.es

01

Descripción del Proyecto

AeroPredictor es un sistema de Machine Learning end-to-end capaz de **predecir la generación diaria de energía eólica en la España peninsular**, combinando datos históricos de producción de Red Eléctrica de España (REE) con datos meteorológicos de la Agencia Estatal de Meteorología (AEMET).

207.354	57,9%	4+ años
MWh previstos hoy	R ² del modelo base	datos históricos

Objetivos principales

- Predecir la producción eólica peninsular del día siguiente en MWh con modelos de ML.
- Integrar datos en tiempo real de las APIs públicas de AEMET y REE de forma automatizada.
- Desplegar el modelo como API REST (FastAPI + Render) con frontend web (Astro + Vercel).
- Comparar múltiples algoritmos y seleccionar el más adecuado según métricas objetivas.

02

Fuentes de Datos

Red Eléctrica de España (REE)

API pública **apidatos.ree.es** sin autenticación. Descarga de estructura de generación diaria desde enero 2022 hasta la fecha actual en tramos de 30 días para evitar timeouts. Los datos se almacenan en SQLite con clave primaria (*datetime, tecnologia*).

AEMET — Agencia de Meteorología

API **opendata.aemet.es** con token gratuito. Climatología diaria de 7 estaciones próximas a los principales parques eólicos peninsulares. Variables: **velmedia** (velocidad media del viento) y **racha** (racha máxima), almacenadas en SQLite con clave (*fecha, indicativo*).

Estaciones meteorológicas AEMET utilizadas

Parque Eólico	Estación AEMET	Provincia	Variables
Andevalo	Huelva aeropuerto	Huelva	velmedia, racha
Gecama	Cuenca	Cuenca	velmedia, racha
Maranchón	Molina de Aragón	Guadalajara	velmedia, racha
Borja	Borja	Zaragoza	velmedia, racha
Tarifa	Tarifa	Cádiz	velmedia, racha
Briviesca	Briviesca	Burgos	velmedia, racha
La Muela	Zaragoza aeropuerto	Zaragoza	velmedia, racha

03

Metodología

1	Adquisición de datos Descarga automatizada de REE (generación diaria) y AEMET (meteorología de 7 estaciones eólicas) mediante sus APIs REST. Almacenamiento incremental en SQLite.
2	Análisis de calidad Diagnóstico de nulos por estación y variable. La energía solar y la hidráulica se descartaron por falta de datos fiables. La eólica presentó cobertura suficiente en las 7 estaciones.
3	Imputación de nulos Se evaluaron 6 métodos (forward fill, backward fill, lineal, cúbico, KNN, media estacional). La interpolación lineal obtuvo el menor RMSE y fue seleccionada.
4	Feature Engineering Construcción de variables: lags del target (1, 2, 3, 7 días), medias móviles del viento (3, 7, 14 días), variables de calendario (mes, día del año, día de la semana).
5	Entrenamiento y evaluación Split temporal 80/20. Se entrenaron 8 modelos distintos y se evaluaron con RMSE, MAE, R^2 y MAPE.
6	Despliegue Backend FastAPI en Render + Frontend Astro en Vercel. El modelo serializado (joblib) se sirve como API REST para predicciones en tiempo real.

Features y Modelos Evaluados

Variables de entrada (features)

Feature	Descripción	Tipo
velmedia	Velocidad media del viento (m/s) — media 7 estaciones	Meteorológica
mes	Mes del año (1–12) — captura estacionalidad invernal	Calendario
día_semana	Día de la semana (0–6)	Calendario
día_año	Día del año (1–365)	Calendario
eolica_lag1/2/3	Generación eólica de 1, 2 y 3 días anteriores (MWh)	Lag target
eolica_lag7	Generación eólica hace 7 días — patrón semanal	Lag target
vel_ma3/7/14	Media móvil del viento a 3, 7 y 14 días	Rolling
eolica_ma7	Media móvil del target (con shift, sin data leakage)	Rolling

Modelos entrenados y evaluados

Modelo	Configuración	Notas
Linear Regression 	StandardScaler	Modelo seleccionado para producción
Ridge ($\alpha=10$)	Regularización L2	Reduce overfitting lineal
Lasso ($\alpha=0.1$)	Regularización L1, selección features	Feature selection implícito
Random Forest	300 estimadores, max_depth=12	Robusto, no lineal
XGBoost	400 est., lr=0.05, depth=6	Gradient boosting eficiente
LightGBM	400 est., lr=0.05	Más rápido que XGBoost
MLP Neural Network	Capas (128, 64, 32), early stopping	Red neuronal densa
SARIMAX(1,0,1)(1,1,1,7)	Exógenas: velmedia + racha	Serie temporal con estacionalidad

05

Resultados y Arquitectura

Métricas del modelo seleccionado (Linear Regression)

R ²	RMSE	MAPE	Split
0.579	~28.000 MWh	en evaluación	80/20 temporal

El modelo explica el 57,9% de la variabilidad en la producción eólica usando únicamente velocidad media del viento y variables de calendario como features. Los modelos de boosting (XGBoost, LightGBM) y el SARIMAX también mostraron resultados competitivos.

Arquitectura de despliegue

Capa	Tecnología	Plataforma	Función
Frontend	Astro + Tailwind CSS	Vercel	Visualización y consulta de predicciones
Backend API	FastAPI + Uvicorn	Render	Sirve el modelo y actualiza predicciones
Modelo ML	scikit-learn + joblib	Render	Linear Regression serializado
Base de datos	SQLite	Render disk	Datos históricos REE + AEMET
Scheduler	APScheduler	Render	Actualización automática nocturna
Datos live	AEMET API + REE API	Internet	Forecast y producción en tiempo real

06

Conclusiones y Líneas de Mejora

Conclusiones

- Correlación clara y consistente entre velocidad media del viento y generación eólica nacional, visible en series temporales y matrices de correlación.
- La interpolación lineal es el método más robusto para rellenar huecos temporales en variables de viento, superando métodos más complejos como la interpolación cúbica.
- El ciclo completo — desde descarga de datos hasta predicción en tiempo real — es viable con APIs públicas gratuitas de AEMET y REE.
- Linear Regression ofrece el mejor equilibrio entre interpretabilidad y rendimiento para este dataset, siendo el modelo seleccionado para producción.
- La energía solar y la hidráulica fueron descartadas por falta de datos fiables de insolación y la baja correlación entre precipitación local y caudal real.

Líneas de mejora futuras

- Incorporar forecast histórico de ECMWF/ERA5 para reemplazar observaciones reales por pronósticos en el entrenamiento, eliminando el sesgo de datos perfectos.
- Añadir más estaciones meteorológicas y variables (presión atmosférica, dirección del viento) para mejorar la representatividad geográfica.
- Explorar arquitecturas LSTM con ventanas temporales más largas para capturar dependencias de largo plazo en la producción eólica.
- Recuperar la predicción fotovoltaica usando datos de irradiancia de satélite (PVGIS o ERA5) en lugar de estaciones terrestres con heliógrafos.
- Implementar reentrenamiento automático periódico del modelo con los nuevos datos acumulados.

■ Proyecto en producción

aero-predictor.joseluisalonsoredondo.es
github.com/jlalsoredon/proyecto_ML_Renovables

■ Autor

José Luis Alonso Redondo
Data Science Bootcamp ·
2026